


Finite Markov Decision Processes (MDPs)

强化学习基本框架



- 每个时间步 t 中:

- 环境给Agent一个 S_t, R_t ,分别为当前的状态与上一轮Action获得的奖励

-

$$R_t \in \mathcal{R} \subset \mathbb{R}, S_t \in \mathcal{S}$$

- Agent由策略 $\pi(a|s)$ 产生一个Action A_t

-

$$A_t \in \mathcal{A}(s)$$

- 下一个时间步产生对应的 R_{t+1}, S_{t+1}

- 产生 R_{t+1}, S_{t+1} 的机制为环境决定, 相当于真实 (且不一定可知的) 的某个给定分布/函数

- 产生序列(sequence)或者轨迹(trajjectory):

-

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, \dots$$

有限马尔可夫决策过程

- 假设1: 状态集, 动作集和奖励集 $(\mathcal{S}, \mathcal{A}, \mathcal{R})$ 均具有有限元素数量

- 假设2：马尔可夫性质：随机变量 R_t, S_t 具有明确定义的离散概率分布，且该分布仅仅取决于前一状态与动作

- $$p(s', r | s, a) \doteq \Pr\{S_t = s', R_t = r \mid S_{t-1} = s, A_{t-1} = a\},$$

- 对于任意的 $s', s \in \mathcal{S}, r \in \mathcal{R}, a \in \mathcal{A}(s), t = 1, 2, \dots$

- 注意这里的p与t无关

- $$\sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, a) = 1, \text{ for all } s \in \mathcal{S}, a \in \mathcal{A}(s)$$

- 也就是环境的动态特性均来自该公式

目标与奖励

- 在每个时间步t后,智能体都会获得该步Action的奖励 R_t
- Agent的目标是最大化其获得的总奖励量，而不是即时奖励
- reward hypothesis:
 - That all of what we mean by goals and purposes can be well thought of as the maximization of the expected value of the cumulative sum of a received scalar signal (called reward)

分段场景(Episodes)与连续场景

Episodes

- 智能体与环境的交互可以自然分解为若干子序列，其中这些子序列称为片段（episodes）
 - 每个片段终止于一个特殊状态——terminal state
 - 然后会重置到标准起始状态或者起始状态的标准分布中采样得到的状态
 - 片段可能以不同方式结束，终止时间T也是一个随机变量，随不同片段而变化
 - 下一片段的开始仍独立与前一片段的结束状态
- 在片段任务中：
 - 包含所有非终止状态的集合 $\mathcal{S}$

- 包含终止状态的全状态集合 $S +$

continuing tasks


- 智能体与环境的交互持续无间断的进行，如机器人任务

回报 (Returns)

- 最大化长期累计奖励的数学形式化：回报 (Returns)
 - 记时间步 t 后获得的奖励序列为 $R_{t+1}, R_{t+2}, \dots$
 - 片段任务回报： $G_t = R_{t+1} + R_{t+2} + \dots + R_T$
 - 连续任务回报(discounted return): $G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$
 - 其中 $0 \leq \gamma \leq 1$
 - Agent而言， γ 越大越远视，越小越短视
 - 只要 R 有界，discounted return就可以收敛
- 递推关系
 - $$\begin{aligned} G_t &\doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 R_{t+4} + \dots \\ &= R_{t+1} + \gamma (R_{t+2} + \gamma R_{t+3} + \gamma^2 R_{t+4} + \dots) \\ &= R_{t+1} + \gamma G_{t+1} \end{aligned}$$
 - 该式子对片段任务回报同样适用， $t < T$ 显然成立，而 $t = T - 1$ 时，令 $G_t = 0$ 即可

Episodic Tasks 与 Continuing Tasks 的统一符号

- 补充：按理对于片段任务，需要额外标明哪个片段，但实际我们当作分析某个特定片段即可，这是没有任何区别的
- 分段式任务转为连续任务：
 - episode termination state 看作进入一个特殊的吸收状态(absorbing state)
 - 这个状态只能转移到自身，且产生的奖励恒为0



- 统一的return

◦

$$G_t = \sum_{k=0}^T \gamma^k R_{t+k+1}$$

◦ 两种情况：

- 连续任务： $T = \infty$
- 片段任务： $\gamma = 1$

策略(Policy)与价值函数(Value Functions)

策略

- 策略是从状态到各种可能动作选择的概率分布的映射
- 如果对于时间步 t 时， $S_t = s$ ， $P(A_t = a | S_t = s) = \pi(a|s)$

状态价值函数

- the state-value function for policy π is denoted by v_π

- 从状态 s 出发，遵循策略 π 的期望回报
- $$v_{\pi}(s) \doteq \mathbb{E}_{\pi}[G_t \mid S_t = s] = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s\right], \text{ for all } s \in \mathcal{S}$$
- 其中 $\mathbb{E}_{\pi}[\cdot]$ 代表在策略 π 给定后，其中随机变量的期望
 - 考虑整个随机过程的每个时间步，随机性无非来自于两个方面
 - 第一是已知 S_t 时， A_t 的选择，这来自于策略这个分布 $\pi(a|s)$
 - 第二是已知 S_t ，做出动作选择 A_t 后，下一轮环境会反馈的 S_{t+1}, A_{t+1} ，这来自于对应的分布 p
- the action-value function for policy q_{π}
 - 在状态 s 选择动作 a 后，遵循策略 π 的期望回报
 - $$q_{\pi}(s, a) \doteq \mathbb{E}_{\pi}[G_t \mid S_t = s, A_t = a] = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s, A_t = a\right]$$

Bellman equation

- Bellman equation for v_{π}

$$\begin{aligned}
 v_{\pi}(s) &\doteq \mathbb{E}_{\pi}[G_t \mid S_t = s] \\
 &= \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\
 &= \sum_a \pi(a|s) \sum_{s'} \sum_r p(s', r | s, a) \left[r + \gamma \mathbb{E}_{\pi}[G_{t+1} | S_{t+1} = s'] \right] \\
 &= \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) \left[r + \gamma v_{\pi}(s') \right], \quad \text{for all } s \in \mathcal{S},
 \end{aligned}$$

- 说明：地三个等式这里外围的 $\mathbb{E}$ 消失了，而里面有了新的 $\mathbb{E}$ ，本质是消除了时间步 t 的动作 A_t 与时间步 $t+1$ 的状态与奖励 S_{t+1}, R_{t+1} 的随机性
 - 但还有之后时间步相关变量的随机性，这里都统一用 $\mathbb{E}$ 表示
 - 而策略 π 这里的标号代表是给定的
- 贝尔曼方程（3.14）对所有可能性按其发生概率进行加权平均

- 核心命题是：起始状态的价值必须等于预期下一状态的（折后）价值加上该过程中预期获得的奖励

最优策略与最优价值函数

最优状态价值函数

- 最优状态价值函数由下式定义（the optimal state-value function）

◦

$$v_*(s) = \max_{\pi} v_{\pi}(s), \text{ for all } s \in \mathcal{S}$$

- 对于MDF过程，存在最佳策略 π^* 可满足最优状态价值函数：

◦

$$v_*(s) = v_{\pi^*}(s), \text{ for all } s \in \mathcal{S}$$

- 这样的最佳策略可能不止一个，我们统一用这个记号，它们有着相同的最优状态价值函数

最优动作价值函数

- 最优动作价值函数由下式定义（the optimal action-value function）

◦

$$q_*(s, a) = \max_{\pi} q_{\pi}(s, a), \text{ for all } s \in \mathcal{S} \text{ and } a \in \mathcal{A}(s)$$

- 对于MDF过程，存在最佳策略 π' 可满足最优动作价值函数：

◦

$$q_*(s, a) = q_{\pi'}(s, a), \text{ for all } s \in \mathcal{S} \text{ and } a \in \mathcal{A}(s)$$

- 这样的最佳策略可能不止一个，我们统一用这个记号，它们有着相同的最优动作价值函数

最佳策略两种定义的统一性

欲证： $\pi^* = \pi'$

$$\begin{aligned}
v_{\pi}(s) &= E_{\pi}[G_t | S_t = s] \\
&= E_a E_{\pi}[G_t | S_t = s, A_t = a] \\
&= E_a q_{\pi}(s, a) \\
&= \sum_a \pi(a|s) q_{\pi}(s, a)
\end{aligned}$$

一些错误的尝试¹

- 斯坦福的RL讲义[OptimalPolicyExistence.pdf](#)
 - 内有证明，两种最佳策略的定义是一致的
 - 证明了最佳策略的存在性
 - 证明了最佳策略就满足最优状态价值函数与最优动作价值函数
 - 但实际不严谨，直觉向的说明，严谨证明需要一整篇论文与好几个假设
- 以下观点直接接受即可：

最佳策略的形式

$$\pi^*(a|s) = \begin{cases} 1, & a = \arg \max_{a'} q_*(s, a') \\ 0, & \text{others} \end{cases}$$

$$v_{\pi^*}(s) = v_*(s), \forall s \in \mathcal{S}$$

$$q_{\pi^*}(s, a) = q_*(s, a), \forall s \in \mathcal{S}, a \in \mathcal{A}(s)$$

$$v_*(s) = \max_a q_*(s, a), \forall s \in \mathcal{S}$$

Bellman optimality equation

$q_{\pi}(s, a)$ 与 $v_{\pi}(s)$

$$\begin{aligned}
q_\pi(s, a) &= E_\pi[G_t | S_t = s, A_t = a] \\
&= E_\pi[R_{t+1} + \gamma G_{t+1} | S_t = s, A_t = a] \\
&= \sum_r \sum_{s'} E_\pi[r + \gamma G_{t+1} | S_t = s, A_t = a, S_{t+1} = s', R_{t+1} = r] p(r, s' | s, a) \\
&= \sum_r \sum_{s'} E_\pi[r + \gamma G_{t+1} | S_{t+1} = s'] p(r, s' | s, a) \\
&= \sum_r \sum_{s'} [r + \gamma v_\pi(s')] p(r, s' | s, a) \\
&= E[R_{t+1} + \gamma v_\pi(S_{t+1}) | S_t = s, A_t = a]
\end{aligned}$$

从而有

$$q_*(s, a) = E[R_{t+1} + \gamma v_*(S_{t+1}) | S_t = s, A_t = a]$$

Bellman optimality equation

$$\begin{aligned}
v_*(s) &= \max_{a \in \mathcal{A}(s)} q_*(s, a) \\
&= \max_a E[R_{t+1} + \gamma v_*(S_{t+1}) | S_t = s, A_t = a] \\
&= \max_a \sum_{s', r} [r + \gamma v_*(s')] p(r, s' | s, a)
\end{aligned}$$

- 在最优策略下某状态的价值必须等于从该状态采取最佳行动所获得的期望回报

$$\begin{aligned}
q_*(s, a) &= \mathbb{E} \left[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a \right] \\
&= \sum_{s', r} p(s', r \mid s, a) \left[r + \gamma \max_{a'} q_*(s', a') \right].
\end{aligned}$$

贝尔曼最佳方程求解

- 若有n个状态，就有n个贝尔曼最佳方程
- 组成了非线性方程组，若已知环境的动态特性p,可直接求解获得 $v_*(s), q_*(s, a)$
- 若已知 $v_*(s)$,可检查对应方程非0的概率项，对应的动作即为最佳动作

- 若已知 $q_*(s, a)$ ，可直接比较大小确定 a
- 由此局部贪婪便实现了全局最优

1. 一些错误的尝试

引理

Lemma : 如果我们已经有策略 $\pi(a|s)$ 与对应的动作价值函数, 定义策略 $\pi'(a|s) = \begin{cases} 1, & a = \arg \max_{a'} q_\pi(s, a') \\ 0, & \text{others} \end{cases}$, 那么:
策略 π' 优于策略 π , 即 $v_\pi(s) \leq v_{\pi'}(s)$

Proof:

$$\begin{aligned} v_\pi(s) &= \sum_a \pi(a|s) q_\pi(s, a) \\ &\leq \max_a q_\pi(s, a) \\ &= v_{\pi'}(s) \end{aligned}$$

继续证明

我们已有最佳策略 π^* ,

$$v_{\pi^*}(s) = \sum_a \pi^*(a|s) q_{\pi^*}(s, a)$$

由引理可知我们有更优的策略 $\pi''(a|s) = \begin{cases} 1, & a = \arg \max_{a'} q_{\pi^*}(s, a') \\ 0, & \text{others} \end{cases}$

且 $v_{\pi^*}(s) \leq v_{\pi''}(s)$, 又有 $v_{\pi''}(s) \leq v_{\pi^*}(s)$

则

$$v_{\pi''}(s) = v_{\pi^*}(s)$$

π'' 也是最佳策略

再考虑

$$v_{\pi''}(s) = \sum_a \pi''(a|s) q_{\pi''}(s, a)$$

由之前对策略 $\pi''(a|s)$ 的定义，

$$v_{\pi''}(s) = q_{\pi''}(s, a')$$

这里的 a' 满足 $a' = \arg \max_a q_{\pi''}(s, a)$, 我们可以想到 a' 也满足 $a' = \arg \max_a q_{\pi'}(s, a)$ (否则存在更大的 $q_{\pi'}(s, a)$, 我们用引理的方法可以定义出严格

又考虑由动作价值函数定义的“最佳策略” π'

$$v_{\pi'}(s) = \sum_a \pi'(a|s) q_{\pi'}(s, a)$$

由引理可得更优策略